Министерство науки и высшего образования Российской Федерации

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ

«Национальный исследовательский университет ИТМО»

(Университет ИТМО)

Факультет программной инженерии и компьютерной техники

Образовательная программа Проектирование и разработка систем больших данных

Направление подготовки 09.04.04 Программная инженерия

Дисциплина Аналитика больших данных

**О Т Ч Е Т**

по домашнему заданию 2

# «Хранилище данных Data Vault на Vertica»

Обучающиеся:

Ермаков Тимофей Сергеевич, группа P4135

Перов Виктор Валерьевич, группа P4135

Преподаватель: доцент, к.т.н.

Королёва Юлия Александровна

Санкт-Петербург

2026

**Цель работы**

Построить хранилище данных по модели Data Vault 2.0 на колоночной СУБД Vertica на основе выгрузок CSV из части социальной сети (люди, группы, чаты). Построить три аналитические витрины и две системные витрины для контроля фоновых процессов: корректности CRON-расписаний и статусов выполнения задач. Визуализировать витрины дашбордами Apache Superset, оркестрировать загрузку через Apache Airflow.

**Исходный код**

https://github.com/mgfallen/adb-itmo

**Цель и постановка задачи**

На основе примеров файлов формата CSV с данными о части социальной сети, построить хранилище с использованием Vertica, используя модель данных Data Vault. Создайте несколько аналитических витрин и две системные витрины. Данные дашборды могут упростить администрирование фоновых процессов, предоставляя администратору единую точку входа для контроля:

- корректности настроенных расписаний (CRON-выражения, наличие всех запланированных задач);

- статусов выполнения задач.

**Исходные данные**

Исходные файлы: people.csv (4 строки), groups.csv (9 строк), chats.csv (10 строк) в папке social_network/data/csv/.

**Таблица 1. Нюансы в исходных данных**

| **Проблема** | **Решение** |
|---|---|
| **Кодировка Windows-1251 (русские буквы)** | Декодирование в UTF-8 Python-загрузчиком до отправки в Vertica |
| **Строки целиком в кавычках с удвоенными внутренними** | Нормализация строк: снятие внешних кавычек, разворот "" перед парсингом |
| **Наносекунды в msg_time (9 знаков)** | Усечение до 6 знаков под точность Vertica TIMESTAMP |
| **Колонка e-mail с дефисом** | Переименование в e_mail |

| | |
|---|---|

**Модель Data Vault**

Архитектура реализована по модели Data Vault 2.0. Хеш-ключи - MD5 от бизнес-ключей (VARCHAR(32)), вычисляются средствами Vertica. Satellites содержат hash_diff для отслеживания истории версий атрибутов.

**Таблица 2.1. Hubs**

| Таблица | Бизнес-ключ | Атрибуты | Строк |
|---|---|---|---|
| h_people | person_id | registration_date | 24 |
| h_groups | group_id | created_date | 15 |
| h_chats | msg_id | msg_time | 10 |

**Таблица 2.2. Links**

| Таблица | Связь | Строк |
|---|---|---|
| l_chat_owners | h_people - h_groups (владение группой) | 9 |
| l_person_chat | h_people - h_chats (participant_role: from/to) | 20 |
| l_groups | h_chats - h_groups (сообщение в группе) | 10 |

Для l_person_chat на каждое сообщение создаются две строки: отправитель (from) и получатель (to) - так слой связей полностью покрывает поток сообщений, а витрины строятся по links, без обращений к satellites.

**Таблица 2.3. Satellites**

| Таблица | Атрибуты | Строк |
|---|---|---|
| s_person_info | name, date_of_birthday, country, phone, e_mail | 4 |
| s_group_info | title, status (по умолчанию active) | 9 |
| s_chat_info | text_msg, status (по умолчанию delivered) | 10 |

Все таблицы созданы с проекциями SEGMENTED BY HASH(hk) ALL NODES и сортировкой по бизнес-ключу и load_date. Повторные прогоны не создают дубликатов: вставка идёт только при отсутствии ключа (хабы и линки) или hash_diff (спутники).

**Архитектура и процесс загрузки**

Инфраструктура разворачивается docker compose: Vertica (single-node), Airflow (LocalExecutor), Apache Superset, два PostgreSQL для метаданных Airflow и Superset. Загрузку выполняют три DAG-а:

**Таблица 3. DAG'и**

| DAG | Назначение | Расписание |
|---|---|---|
| load_social_dv | DDL → staging (COPY) → хабы → линки → спутники | ручной запуск |
| build_marts | Пересборка аналитических витрин из staging и dvs | 0 4 * * * |
| sys_marts_refresh | Системные витрины из метаданных Airflow (DagBag + task_instance) | 30 4 * * * |

**Аналитические витрины**

Витрины собираются из слоёв staging и dvs с LEFT JOIN - отсутствующие ключи попадают в отчёт с NULL.

**Таблица 4.1. dm_person_activity - активность участников**

| person_id | name | groups_owned | messages_sent | messages_received |
|---|---|---|---|---|
| 1818 | - | 0 | 3 | 0 |
| 445074 | - | 0 | 2 | 0 |
| 41492 | - | 0 | 2 | 0 |
| 171717 | - | 0 | 0 | 4 |
| 36370 | - | 0 | 0 | 3 |

**Таблица 4.2. dm_group_activity - активность групп**

| group_id | title | owner_id | messages_count | members_count |
|---|---|---|---|---|
| 7777 | - | - | 2 | 2 |
| 47 | - | - | 1 | 2 |
| 5 | Группа6 | 117846 | 1 | 2 |
| 4 | Группа5 | 51744 | 1 | 2 |
| 7 | Группа8 | 149546 | 1 | 2 |

**Таблица 4.3. dm_message_stats - статистика по дням**

| stat_date | messages_total | group_messages | private_messages | messages_with_link | avg_text_length |
|---|---|---|---|---|---|
| 2023-06-05 | 1 | 1 | 0 | 0 | 11.0 |
| 2023-06-18 | 1 | 1 | 0 | 0 | 6.0 |
| 2024-03-05 | 1 | 1 | 0 | 1 | 51.0 |
| 2024-05-13 | 2 | 2 | 0 | 0 | 7.5 |

**Системные витрины**

sys_cron_schedule формируется из DagBag (расписания всех задач, включая ни разу не запускавшиеся) с валидацией CRON-выражений библиотекой croniter: has_schedule, is_valid_cron, next_fire_time, prev_fire_time. sys_task_runs строится из таблиц task_instance и содержит состояние, длительность и число попыток каждой задачи.

**Таблица 5. Настройка расписания**

| dag_id | task_id | cron_expression | is_valid_cron | has_schedule | next_fire_time |
|---|---|---|---|---|---|
| build_marts | build_all_marts | 0 4 * * * | true | true | 2026-11-01 04:00 |
| sys_marts_refresh | refresh_sys_marts | 30 4 * * * | true | true | 2026-10-31 04:30 |
| load_social_dv | load_staging | - | false | false | - |

# Дашборды Superset

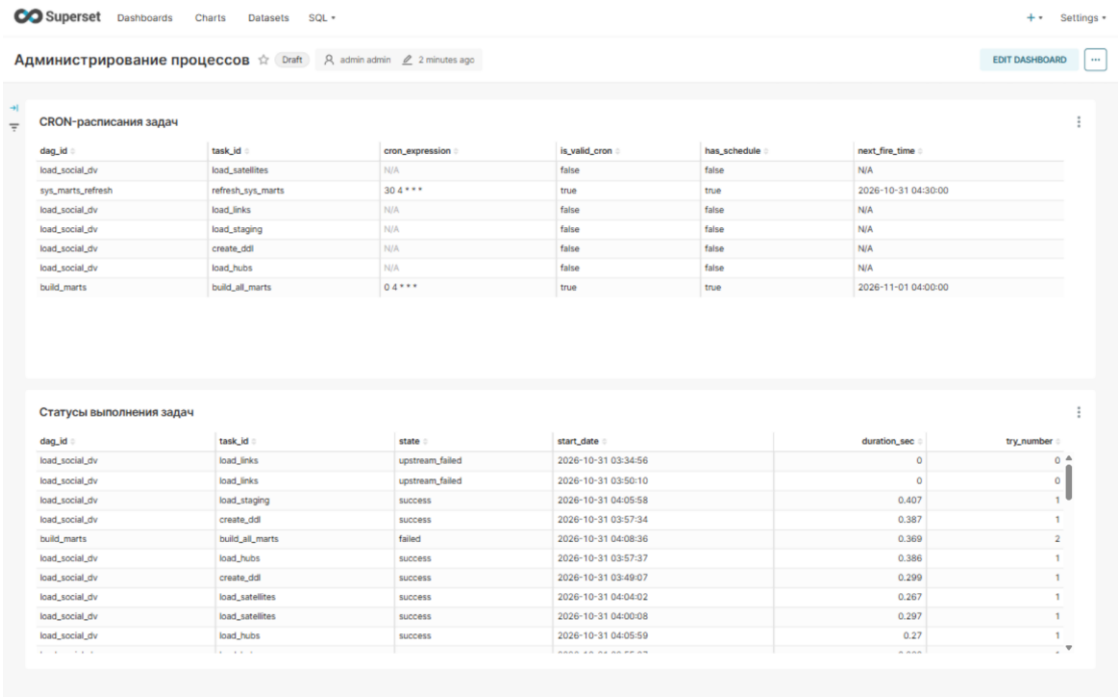



Рис. 1. Дашборд «Администрирование процессов»

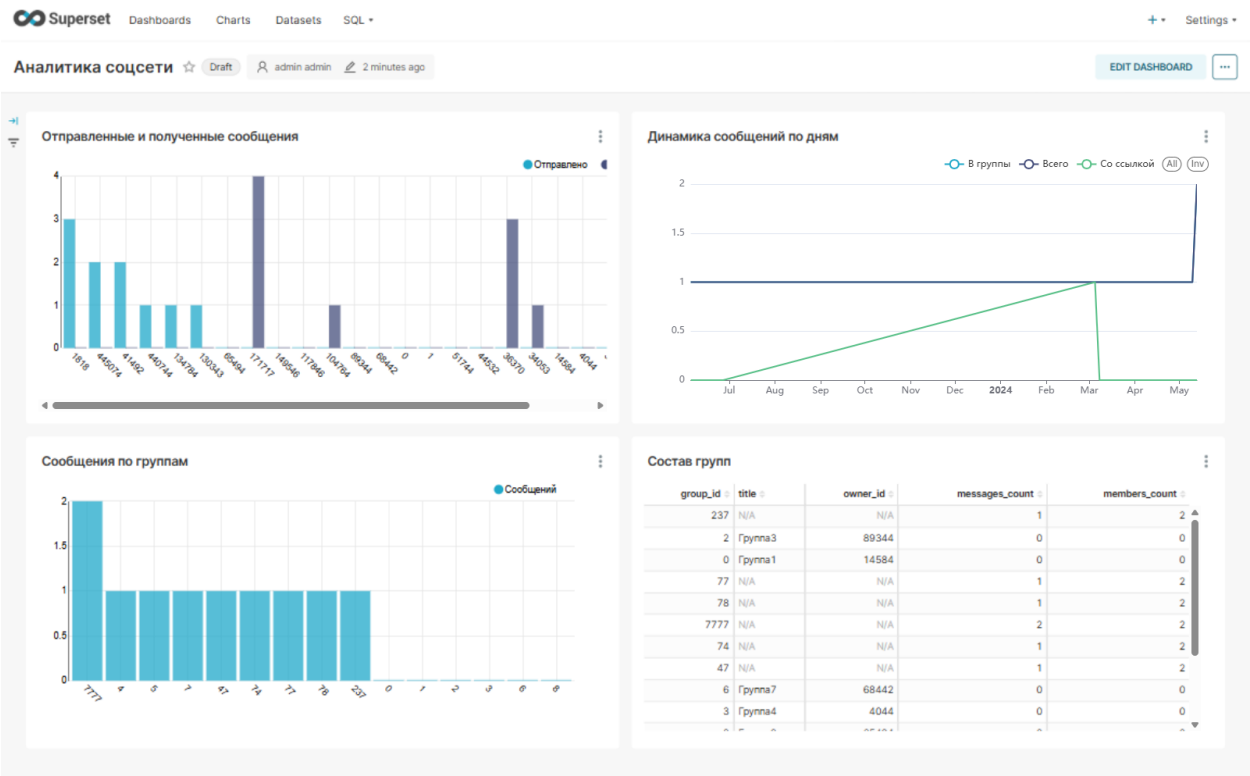



Рис. 2. Дашборд «Аналитика соцсети»

**Запуск**

**Таблица 6. Команды для запуска**

| **Шаг** | **Команда** |
|---|---|
| Создать .env из шаблона | cp .env.example .env |
| Поднять инфраструктуру | docker compose up --build -d |
| Загрузить Data Vault | Airflow: запустить DAG load_social_dv |
| Построить витрины | Airflow: DAG build_marts, sys_marts_refresh |
| Дашборды | http://localhost:8088 (admin/admin12345) |
| Пересоздать контент Superset | python scripts/superset_setup.py |

**Выводы**

Построено рабочее хранилище Data Vault 2.0 на Vertica с полной автоматизацией через Airflow. Hubs консолидируют ключи из всех источников, satellites подключают описательные атрибуты по мере появления. Витрины закрывают потребность администратора в единой точке контроля расписаний и статусов фоновых процессов. Изучена специфика Vertica: колоночное хранение, проекции с сегментацией по хеш-ключам, COPY-загрузка с staging таблицами.